

RELATÓRIO TÉCNICO

Sprint 2 — Manutenção Preditiva de Motores Industriais

Análise Exploratória, Modelo Baseline e Agente Conversacional com Function Calling

Classificação multiclasse de falhas em motores industriais | motor.db | 30.000 leituras

Integrantes do Grupo

Matheus Mikio — RM 561864

Henry Gimenez — RM 563217

Ian Nobres — RM 561681

Gustavo Balbo — RM 561711

Vinicius Araujo — RM 564504

Projeto de Manutenção Preditiva — IA Aplicada
2025

1. Descrição do Problema Preditivo

A manutenção preditiva de motores industriais é uma das aplicações de maior retorno econômico em Machine Learning aplicado a indústria. Falhas não previstas causam paradas não planejadas, danos em cascata e riscos à segurança dos operadores. A antecipação dessas falhas por meio de leituras contínuas de sensores — rotação (RPM), vibração (mm/s), temperatura (graus C) e corrente elétrica (A) — permite que intervenções sejam programadas em janelas de manutenção planejadas, reduzindo o custo por intervenção em até cinco vezes em comparação com a manutenção corretiva.

A tarefa foi formulada como classificação multiclasse: dado um vetor de leituras de sensores de um motor, o modelo deve prever a qual das quatro classes operacionais aquela leitura pertence.

Código	Classe	Descrição Física	Sensores Primários
0	Normal	Operação sem anomalia detectada	Todos dentro do nominal
1	Desbalanceamento	Desbalanceamento do rotor — força centrífuga	Vibração acima de 7 mm/s, RPM instável
2	Superaquecimento	Sobrecarga ou falha no resfriamento	Temperatura acima de 85 C, Corrente acima de 15 A
3	Falha mecânica	Desgaste de rolamentos ou eixo	Vibração alta + Temperatura alta + RPM em queda

Hipótese central: as leituras dos 4 sensores carregam sinal suficiente para discriminar os 3 tipos de falha com antecedência de até 5 horas (30 leituras x 10 minutos cada), correspondendo a rampa progressiva de deterioração simulada no banco de dados.

2. Descrição da Base de Dados

2.1 Origem e Geração

A base de dados foi gerada sinteticamente pelo script `gerar_banco.py` com seed fixo (42), garantindo reprodutibilidade total. Para recriar o banco do zero, basta executar o comando `python gerar_banco.py`. O arquivo `motor.db` é um banco SQLite composto por três tabelas relacionadas:

Tabela	Linhas	Descrição
tipos_falha	4	Dicionário das 4 classes: código, nome e descrição física de cada falha
motores	20	Cadastro dos motores: fabricante, modelo, potência nominal e data de instalação
leituras	30.000	Série temporal: 20 motores x 1.500 leituras, intervalo de 10 minutos entre cada registro

2.2 Distribuição da Variável-Alvo

A variável-alvo é a coluna `falha` da tabela `leituras`, que assume quatro valores inteiros correspondentes ao estado operacional do motor em cada instante de tempo.

Código	Classe	Quantidade	Proporção	Razão vs Normal
0	Normal	27.426	91,4%	Classe majoritária
1	Desbalanceamento	681	2,3%	1 para 40
2	Superaquecimento	770	2,6%	1 para 36
3	Falha mecânica	1.123	3,7%	1 para 24

O forte desbalanceamento (~91% Normal vs ~8,6% Falhas) é característico de aplicações reais de manutenção preditiva. Um modelo trivial que sempre preveja Normal atingiria 89,3% de acurácia com F1-Macro de apenas 23,6%. Por isso, a métrica principal de avaliação é o F1-Macro nas classes de falha — não a acurácia global.

2.3 Padrões de Falha e Rampa de Deterioração

Cada falha é introduzida com uma rampa progressiva de 30 leituras (equivalente a 300 minutos) antes de atingir sua amplitude máxima. Esse mecanismo simula a degradação real de equipamentos e representa o maior desafio do modelo: detectar o início da falha quando o desvio dos sensores ainda é sutil e próximo ao nível de ruído da operação normal.

3. Análise Exploratória de Dados

3.1 Distribuição das Classes

O gráfico a seguir confirma o desbalanceamento severo da base: 91,4% das leituras são normais, enquanto as três classes de falha somam apenas 8,6%. A classe mais rara é Desbalanceamento (2,3%), com razão de 1 para 40 em relação a classe Normal. Esse perfil exige o uso de `class_weight='balanced'` no treinamento e a adoção do F1-Macro como métrica principal de avaliação.




Figura 1 — Distribuição da variável-alvo. 91,4% das leituras são normais; as três classes de falha somam 8,6%.

3.2 Distribuição dos Sensores por Classe de Falha

Os boxplots abaixo mostram a distribuição de cada sensor separada por classe, com uma linha tracejada indicando o valor nominal de referência. Essa visualização é fundamental para identificar quais sensores carregam mais sinal para cada tipo de falha:

- **Vibração:** a classe Desbalanceamento apresenta mediana entre 7 e 9 mm/s, representando um desvio de 180% a 260% acima do nominal de 2,5 mm/s. É o sensor mais discriminativo para essa classe. Fisicamente, o desbalanceamento do rotor gera forças centrífugas que se propagam como vibração na estrutura do motor.
- **Temperatura:** o Superaquecimento exibe mediana acima de 90 graus C contra cerca de 65 graus C no nominal, um desvio de 38%. Fisicamente, sobrecarga elétrica ou falha no sistema de resfriamento elevam a temperatura dos enrolamentos.
- **Corrente:** também sobe significativamente no Superaquecimento, atingindo cerca de 18 A contra 12 A nominais (acréscimo de 50%). A relação temperatura-corrente é de natureza física: maior corrente gera mais calor pelo efeito Joule.
- **Rotação:** a Falha Mecânica apresenta queda gradual de RPM além de vibração elevada. O desgaste dos rolamentos aumenta o atrito mecânico, reduzindo a velocidade angular do motor sob carga constante.




Figura 2 — Boxplots dos sensores por classe. A linha tracejada indica o valor nominal. Vibração e Temperatura são os sensores de maior poder discriminativo.

3.3 Evolução Temporal e Rampa de Deterioração

O gráfico a seguir ilustra a evolução temporal dos quatro sensores em um motor com falha mecânica. A zona laranja corresponde aos primeiros 30 pontos de cada janela de falha — a rampa progressiva de deterioração — e a zona vermelha corresponde a falha em plena amplitude. Essa distinção é fundamental: o desafio real da manutenção preditiva não é classificar a falha quando ela está em amplitude máxima, mas sim detectá-la ainda na zona laranja, antes que o dano se torne irreversível.



Figura 3 — Evolução temporal dos sensores. Zona laranja: rampa de deterioração (30 leituras). Zona vermelha: falha em plena amplitude. Os erros do modelo concentram-se na zona laranja.

3.4 Correlação entre Sensores

A análise de correlação foi realizada em três perspectivas: global (todas as leituras), apenas nas leituras com falha e apenas nas leituras normais. Essa comparação revela que as correlações relevantes para o diagnóstico emergem somente nas janelas de falha, sendo praticamente ausentes durante a operação normal.

- Temperatura e Corrente apresentam correlação positiva forte apenas nas falhas — sobem juntas no Superaquecimento. Esse padrão é invisível nos dados normais.
- Rotação e vibração apresentam correlação negativa nas falhas: quando a rotação cai (desgaste de rolamentos), a vibração sobe simultaneamente. Esse par de sensores em movimento oposto é a assinatura mais característica da falha mecânica.
- A ausência de correlações fortes nos dados normais confirma que os sensores operam de forma independente em condições regulares de funcionamento.




Figura 4 — Mapas de correlacao nas tres perspectivas. As correlacoes diagnosticas emergem exclusivamente nas janelas de falha.

3.5 Detecção de Outliers

A análise pelo método IQR (1,5 vezes o intervalo interquartil) identificou valores atípicos nos quatro sensores. A coluna '% que são falha' na tabela abaixo e a informação mais relevante: a grande maioria dos outliers pertence às classes de falha, ou seja, eles não são erros de medição, mas sim o principal sinal preditivo do modelo.

Sensor	Outliers	% do Total	% que sao Falha	Decisao
rotacao_rpm	104	0,35%	~64%	Preservar — incluem falha mecanica
vibracao_mm_s	1.766	5,89%	>95%	Preservar — principal sinal de desbalanceamento
temperatura_c	672	2,24%	>90%	Preservar — principal sinal de superaquecimento
corrente_a	616	2,05%	>88%	Preservar — sinal complementar de superaquecimento




Figura 5 — Violinplots por classe com identificacao dos outliers. A maioria dos valores atipicos pertence as classes de falha e foi preservada no treinamento.

3.6 Variabilidade entre Motores

Cada motor possui parâmetros nominais levemente distintos, simulando a variabilidade real de fabricação e instalação. O gráfico abaixo mostra a taxa de falha, a vibração média e a temperatura média de cada um dos 20 motores.




Figura 6 — Taxa de falha por motor, dispersão vibração x temperatura e distribuição da taxa entre os 20 equipamentos.

- A taxa de falha varia de forma expressiva entre os motores. Em um cenário real, isso indicaria diferenças de carga de trabalho, qualidade de instalação ou grau de desgaste acumulado.
- Motores com alta taxa de falha e vibração média acima da média do grupo são candidatos prioritários a inspeção preventiva.
- A heterogeneidade entre motores justifica a inclusão de fabricante e modelo como features categóricas no modelo preditivo.

3.7 Separabilidade das Classes — Pairplot

O pairplot confirma visualmente quais pares de sensores melhor separam as quatro classes no espaço bidimensional.




Figura 7 — Pairplot das classes (amostra de 300 leituras por classe). O par Vibração x Temperatura apresenta a maior separabilidade visual.

- O par Vibração x Temperatura é o mais discriminativo: Desbalanceamento ocupa vibração alta com temperatura normal; Superaquecimento ocupa temperatura alta com vibração baixa; Falha Mecânica ocupa vibração moderada a alta com temperatura moderada.
- A classe Normal concentra-se no núcleo denso de todas as distribuições, confirmando que as falhas representam desvios em relação ao padrão de operação regular.

4. Tratamento e Preparação dos Dados

4.1 Valores Ausentes

Nenhum valor nulo foi identificado nos 30.000 registros da tabela leituras. A verificação foi realizada explicitamente no notebook por meio de `df[SENSOR_COLS].isnull().sum()`, que retornou zero para todas as colunas de sensor.

4.2 Codificação de Variáveis Categóricas

As colunas fabricante e modelo do cadastro de motores foram codificadas como variáveis inteiras por meio de `LabelEncoder`. Essas features foram incluídas no conjunto de treinamento para que o modelo possa capturar eventuais padrões específicos por fabricante ou modelo de equipamento.

4.3 Feature Engineering — Janelas Moveis

A principal contribuição de engenharia de features deste projeto foi a criação de variáveis de janela móvel para cada sensor, com janela de 5 leituras (equivalente a 50 minutos). O objetivo é capturar a tendência de subida dos sensores durante a rampa de deterioração — sinal que não aparece em um único valor pontual, mas se torna visível quando se observa a série ao longo do tempo.

Feature	Calculo	Objetivo Principal
col_mean5	Media dos ultimos 5 valores do sensor	Capturar tendência crescente; suaviza ruído e revela a rampa
col_std5	Desvio padrao dos ultimos 5 valores	Capturar instabilidade do sinal; RPM instavel no desbalanceamento

Total de features utilizadas: 14

4 sensores brutos + 4 medias moveis (mean5) + 4 desvios moveis (std5) + 2 features categóricas

Nota tecnica: as features mean5 e std5 sao calculadas sobre o dataframe completo antes da divisao

treino/teste. As 5 primeiras leituras do conjunto de teste de cada motor (100 de 6.000 = 1,7%)

utilizam dados do treino na janela de transicao. O impacto pratico e minimo, mas e documentado.

4.4 Estrategia para o Desbalanceamento de Classes

O desbalanceamento foi tratado com o parâmetro `class_weight='balanced'` do `RandomForestClassifier`, que ajusta automaticamente o peso de cada amostra de forma

inversamente proporcional a frequência de sua classe no conjunto de treino. Essa abordagem foi preferida ao SMOTE pelos seguintes motivos:

- Não cria amostras sintéticas que poderiam cruzar fronteiras temporais entre janelas de falha, evitando introdução de leakage artificial.
- É aplicável diretamente ao algoritmo, sem etapas externas de reamostragem que complicariam o pipeline.
- É amplamente validada na literatura de manutenção preditiva para séries temporais industriais.

5. Divisão dos Dados para Treinamento e Avaliação

Como a tabela leituras é uma série temporal por motor, a divisão foi realizada de forma estritamente cronológica: as últimas 300 leituras de cada motor (correspondentes às últimas 50 horas monitoradas) foram reservadas para o conjunto de teste. As 1.200 leituras anteriores de cada motor compuseram o conjunto de treino.

Conjunto	Leituras por Motor	Total	Período
Treino	1.200 primeiras	24.000	Leituras de 1 a 1.200 de cada motor
Teste	300 últimas	6.000	Leituras de 1.201 a 1.500 de cada motor

A divisão aleatória seria tecnicamente incorreta para este problema: leituras futuras de uma mesma janela de falha vazariam para o conjunto de treino, ensinando o modelo com informação que não estaria disponível em produção. Esse vazamento inflaria artificialmente as métricas de avaliação e produziria um modelo que não generaliza para dados novos. A divisão cronológica garante que o modelo sempre aprende com o passado e é avaliado sobre o futuro.

6. Treinamento do Modelo Baseline

6.1 Modelos Treinados

Dois modelos foram treinados para permitir uma comparação sistemática entre uma abordagem linear e uma abordagem de ensemble baseada em árvores de decisão.

Modelo	Justificativa	Normalização
Random Forest (modelo principal)	Robusto a escalas diferentes entre features; suporte nativo a <code>class_weight</code> ; fornece importância das features; bom desempenho em dados tabulares com ruído	Não necessária
Regressão Logística (baseline linear)	Avalia se a separabilidade das classes é linear; serve de referência inferior para quantificar o ganho do modelo não-linear	<code>StandardScaler</code> aplicado via Pipeline

Nota técnica: o `StandardScaler` é aplicado exclusivamente ao Pipeline da Regressão Logística, onde é obrigatório. O Random Forest utiliza as features brutas sem normalização, pois árvores de decisão são invariantes à escala dos dados.

6.2 Hiperparâmetros do Random Forest

Parâmetro	Valor	Justificativa
<code>n_estimators</code>	200	200 árvores: equilíbrio entre desempenho e tempo de treinamento
<code>max_depth</code>	20	Profundidade máxima: controla o overfitting sem limitar a expressividade do modelo
<code>min_samples_leaf</code>	5	Mínimo de amostras por folha: evita folhas com poucas amostras ruidosas
<code>class_weight</code>	'balanced'	Peso de cada amostra inversamente proporcional à frequência de sua classe
<code>n_jobs</code>	-1	Paralelização em todos os núcleos de processamento disponíveis
<code>random_state</code>	42	Seed para garantir reprodutibilidade dos resultados

7. Avaliação do Desempenho

7.1 Comparação Random Forest x Regressão Logística

O gráfico abaixo apresenta a comparação das métricas de precisão, recall e F1-Score por classe entre os dois modelos treinados.




Figura 8 — Comparacao de metricas por classe entre Random Forest e Regressao Logistica. O RF supera a LR em todas as classes de falha.

Metrica	Random Forest	Reg. Logistica	Diferenca
Acurácia global (teste)	99,02%	94,48%	RF +4,5pp
F1-Macro (teste)	95,50%	80,76%	RF +14,7pp
F1-Macro (treino)	99,71%	78,99%	RF mais expressivo
Gap overfitting (treino-teste)	4,21pp	-1,77pp	LR mais estavel
Recall — Desbalanceamento	88%	~65%	RF +23pp
Recall — Superaquecimento	95%	~88%	RF +7pp
Recall — Falha Mecânica	92%	~72%	RF +20pp

7.2 Métricas por Classe — Random Forest

Classe	Precisao	Recall	F1-Score	Suporte	Interpretacao
Normal (0)	99,39%	99,93%	99,66%	5.357	Excelente — classe majoritaria bem aprendida
Desbalanceamento (1)	96,76%	88,18%	92,27%	203	Atencao — 12% das falhas nao detectadas (falsos negativos)
Superaquecimento (2)	100,0%	94,66%	97,25%	131	Excelente — precisao perfeita, recall alto
Falha mecanica (3)	93,44%	92,23%	92,83%	309	Bom — classe mais desafiadora pelo sinal misto

Ponto crítico: Recall do Desbalanceamento = 88,18%.

Isso significa que 1 em cada 8 falhas por desbalanceamento passa despercebida pelo modelo.

Em manutenção preditiva, falsos negativos são mais custosos que falsos positivos: um alarme extra gera uma inspeção; uma falha não detectada pode destruir o motor. Este é o principal alvo de melhoria para a próxima etapa do projeto.

7.3 Matriz de Confusão

A matriz de confusão abaixo apresenta os resultados tanto em valores absolutos quanto normalizados por classe real (equivalente ao recall de cada célula), facilitando a leitura da taxa de acerto e dos padrões de erro.




Figura 9 — Matriz de confusão absoluta (esquerda) e normalizada por classe real (direita). Principal padrão de erro: Desbalanceamento confundido com Falha Mecânica (17 casos).

Real \ Previsto	Normal	Desbalanceamento	Superaquecimento	Falha mecânica
Normal (5.357)	5.353	1	0	3
Desbalanceamento (203)	7	179	0	17
Superaquecimento (131)	7	0	124	0
Falha mecânica (309)	19	5	0	285

7.4 Importância das Features

O gráfico abaixo mostra a importância individual e acumulada por grupo de features segundo o critério de Gini do Random Forest.




Figura 10 — Importancia das features por feature individual (esquerda) e por grupo (direita). As medias moveis dominam o ranking, confirmando o valor do feature engineering temporal.

- As features de media movel (mean5) dominam a importancia total, pois capturam a tendencia gradual de subida dos sensores durante a rampa de deterioracao — o principal sinal preditivo do problema.
- O sensor bruto de vibracao aparece com alta importancia individual: para o Desbalanceamento, o desvio e abrupto e ja e visivel no valor pontual.
- As features categoricas de fabricante e modelo apresentam importancia residual nos dados sinteticos, mas poderiam ser mais relevantes em dados industriais reais.

7.5 Curvas ROC Multiclasse

As curvas ROC one-vs-rest fornecem uma perspectiva complementar ao F1-Score, especialmente util em problemas com desbalanceamento de classes.




Figura 11 — Curvas ROC one-vs-rest para as quatro classes. AUC medio de 0,983 indica alta separabilidade no espaco de probabilidades.

Classe	AUC-ROC	Interpretacao
Normal (0)	0,9851	Alta separabilidade — classe majoritaria bem definida
Desbalanceamento (1)	0,9879	Melhor AUC entre as falhas — sinal de vibracao muito discriminativo
Superaquecimento (2)	0,9779	Excelente — temperatura e corrente altamente correlacionadas na falha
Falha mecanica (3)	0,9815	Excelente — apesar do sinal misto com multiplos sensores
Media macro	0,9831	Confirmado pelo F1-Macro de 95,5% nas classes de falha

8. Análise dos Erros do Modelo

8.1 Panorama Geral

De 6.000 previsões realizadas no conjunto de teste, 59 foram incorretas, representando uma taxa de erro de 0,98%. A análise detalhada desses 59 casos revela três padrões sistemáticos que orientam as melhorias para a próxima etapa.

Combinação de Erro	Quantidade	Causa Provável
Desbalanceamento previsto como Normal	7	Início da rampa: vibração ainda próximo ao nível de ruído normal
Desbalanceamento previsto como Falha Mecânica	17	Ambas as classes elevam a vibração; o diferenciador (queda de RPM) ainda é fraco
Superaquecimento previsto como Normal	7	Início da rampa: temperatura ainda em zona de transição
Falha Mecânica prevista como Normal	19	Início da rampa: padrão misto ainda não consolidado
Falha Mecânica prevista como Desbalanceamento	5	Vibração elevada domina sobre os demais indicadores
Outros	4	Casos atípicos em motores com parâmetros nominais incomuns

8.2 Erros Concentrados no Início da Rampa

O histograma abaixo compara a distribuição dos valores de sensor nas leituras com falha classificadas corretamente (verde) versus as classificadas incorretamente (vermelho). A análise confirma que os erros ocorrem predominantemente quando os valores dos sensores ainda estão próximos ao nominal — ou seja, nos primeiros 10 a 15 pontos da janela de falha, antes que o desvio se consolide.




Figura 12 — Distribuicao dos sensores nas leituras com falha: acertos (verde) vs erros (vermelho). Os erros se concentram nos valores mais proximos do nominal.

Sensor	Media nos Acertos	Media nos Erros	Nominal	Conclusao
rotacao_rpm	1.724,60	1.742,16	~1750	Erros com RPM mais alto — falha mecanica nao consolidada
vibracao_mm_s	6,97	3,48	~2,5	Erros com vibracao proximo ao nominal — inicio da rampa
temperatura_c	78,91	65,60	~65	Erros com temperatura quase nominal — rampa ainda nao visivel
corrente_a	13,04	11,99	~12	Erros com corrente nominal — superaquecimento nao consolidado

8.3 Concentracao de Erros por Motor

Os 59 erros nao se distribuem uniformemente entre os 20 motores: cinco equipamentos (IDs 4, 6, 8, 15 e 17) concentram 51 dos 59 erros totais (87%). Esse padrao indica que esses motores possuem parametros nominais incomuns em relacao ao restante do conjunto de treino, dificultando a generalizacao do modelo para eles. A analise individual desses equipamentos e uma das acoes prioritarias da proxima etapa.

9. Discussão Crítica das Métricas

Esta seção responde a questão tecnicamente relevante: por que F1-Macro de 95,5% e acuracia de 99% não indicam overfitting clássico, mas ao mesmo tempo revelam limitações importantes que precisam ser endereçadas?

9.1 Diagnostico de Overfitting

Modelo	F1-Macro Treino	F1-Macro Teste	Gap	Classificacao
Random Forest	99,71%	95,50%	4,21pp	Overfitting moderado
Regressao Logistica	78,99%	80,76%	-1,77pp	Sem overfitting (underfitting leve)

O gap de 4,21pp no Random Forest indica que o modelo memorizou alguns padrões específicos de motores individuais presentes no treino que não generalizam perfeitamente para os dados de teste. Esse nível de overfitting é esperado para Random Forest com `max_depth=20` em um conjunto de 24.000 amostras e pode ser reduzido na próxima etapa com ajuste de hiperparâmetros.

9.2 Por que as Metricas de Teste Sao Elevadas

- Dados sintéticos com padrões de separabilidade alta: o banco foi gerado com desvios deliberadamente grandes nas janelas de falha (vibração +5 a +10 mm/s, temperatura +20 a +40 graus C). Em dados industriais reais, os desvios são menores, mais ruidosos e frequentemente sobrepostos.
- Ausência de falhas ambíguas por design: no banco sintético, cada janela de falha possui tipo e intensidade pre-definidos. Dados reais frequentemente apresentam falhas mistas, transições graduais e eventos não modelados.
- A acurácia de 99% é menos impressionante do que parece: um modelo trivial que sempre preveja Normal atingiria 89,3% de acurácia com F1-Macro de apenas 23,6%. O ganho real do modelo baseline é de 9,7pp em acurácia e de 71,9pp em F1-Macro.
- AUC-ROC médio de 0,983 é coerente com os dados sintéticos: em aplicações industriais reais, espera-se AUC entre 0,85 e 0,95 para este tipo de problema.
- Recall de 88% no Desbalanceamento é o ponto mais crítico: 1 em cada 8 falhas por desbalanceamento passa despercebida. Em produção industrial, isso é inaceitável — um motor com desbalanceamento não detectado pode evoluir para falha mecânica catastrófica em poucas horas. Este é o principal alvo de melhoria da próxima etapa do projeto.

Conclusão: as métricas obtidas são tecnicamente corretas e coerentes com a natureza sintética dos

dados, que possuem padroes de falha intencionalmente bem definidos. Em dados industriais reais

com maior ruido e padroes mais sutis, espera-se queda de 10 a 15pp no F1-Macro.

O ponto mais critico nao e o overfitting em si, mas o Recall de 88% no Desbalanceamento: 1 em cada 8 falhas desse tipo nao e detectada. Esse numero precisa superar 92% na proxima etapa.

10. Agente Conversacional com Function Calling

10.1 Arquitetura

O agente converte linguagem natural em chamadas estruturadas ao modelo de Machine Learning. A implementacao integra tres camadas funcionais:

Camada	Componente	Responsabilidade
Interface	Loop de chat em Python	Receber mensagem do usuario e manter o historico da conversa
LLM	Claude (claude-sonnet-4)	Interpretar linguagem natural, decidir quando invocar a tool e gerar a resposta explicativa
Tool / Modelo	prever_falha_motor() + RF	Executar a predicao, calcular os desvios dos sensores e retornar JSON estruturado

10.2 Tool Registrada

A tool `prever_falha_motor(rotacao_rpm, vibracao_mm_s, temperatura_c, corrente_a)` foi registrada no formato Anthropic `tool_use` com quatro parametros obrigatorios. O retorno e um objeto JSON contendo: classe prevista, diagnostico textual, probabilidades para cada uma das quatro classes, nivel de confianca, desvios percentuais por sensor e lista de alertas para sensores com desvio superior a 15% do valor nominal.

10.3 Demonstracao — Tres Cenarios

Cenario 1 — Motor em Operacao Normal

Sensor	Valor Informado	Desvio do Nominal
Rotacao	1748 RPM	-0,1% — dentro do nominal
Vibracao	2,6 mm/s	+4% — dentro do nominal
Temperatura	67 C	+3% — dentro do nominal
Corrente	12,1 A	+1% — dentro do nominal

DIAGNOSTICO: Normal (confianca: 75,3%)
Normal 75,3% | Falha Mecanica 11,0% | Desbalanceamento 8,9% | Superaquecimento 4,8%

Todos os sensores dentro dos parametros nominais.
Recomendacao: monitoramento rotineiro conforme o plano de manutencao vigente.

Cenario 2 — Superaquecimento Claro

Sensor	Valor Informado	Desvio do Nominal
Rotacao	1745 RPM	-0,3% — normal
Vibracao	2,8 mm/s	+12% — normal
Temperatura	104 C	+60% — CRITICO
Corrente	18,5 A	+54% — CRITICO

DIAGNOSTICO: Superaquecimento (confianca: 55,8%)

Superaquecimento 55,8% | Normal 28,0% | Falha Mecanica 13,2% | Desbalanceamento 3,0%

Alertas: temperatura 60% acima do nominal (104 C vs 65 C); corrente 54% acima (18,5 A vs 12 A)

Recomendacao: CRITICO — verificar carga, sistema de refrigeracao e isolamento termico imediatamente.

Cenario 3 — Leituras Ambiguas com Incerteza

Sensor	Valor Informado	Desvio do Nominal
Rotacao	1720 RPM	-1,7% — levemente abaixo
Vibracao	5,1 mm/s	+104% — ALTO
Temperatura	78 C	+20% — elevado
Corrente	14,2 A	+18% — elevado

DIAGNOSTICO: Falha Mecanica (confianca: 60,1%)

Falha Mecanica 60,1% | Normal 15,2% | Desbalanceamento 13,3% | Superaquecimento 11,4%

[INCERTEZA] Diferenca de apenas 13,3% entre Falha Mecanica e Desbalanceamento.

Sinal misto: vibracao muito elevada (consistente com desbalanceamento), mas a queda de RPM

e a temperatura acima do normal apontam para inicio de falha mecanica nos rolamentos.

Recomendacao: URGENTE — inspecionar rolamentos e balanceamento do rotor.

Monitorar a cada 30 minutos e acionar equipe tecnica para avaliacao presencial.

11. Código e Organização do Experimento

Arquivo	Tipo	Descrição
gerar_banco.py	Python	Gera o motor.db do zero com seed=42; funções separadas e saída de resumo automática
motor.db	SQLite	Banco com 30.000 leituras de sensores (20 motores x 1.500)
BANCO.md	Markdown	Documentação completa do schema, padrões de falha e limites de referência
analise_exploratoria.ipynb	Notebook	EDA completa: 7 seções, 7 figuras, interpretações físicas em células markdown
treinamento.ipynb	Notebook	Pipeline ML: feature engineering, divisão temporal, treino, avaliação e análise de erros
modelo_falhas.joblib	Binário	Modelo serializado com features, label map e métricas do teste embutidas
agente_manutencao.py	Python	Agente conversacional com tool_use Anthropic e modo de demonstração offline
requirements.txt	Texto	Dependências Python com versões mínimas definidas
README.md	Markdown	Instruções de instalação, execução e descrição dos resultados

11.1 Instruções de Reprodução

- Instalar dependências: `pip install -r requirements.txt`
- (Opcional) Recriar o banco: `python gerar_banco.py`
- Executar a EDA: `jupyter notebook analise_exploratoria.ipynb`
- Executar o treinamento: `jupyter notebook treinamento.ipynb`
- Demonstração do agente (sem chave de API): `python agente_manutencao.py --demo`
- Agente interativo com LLM: `export ANTHROPIC_API_KEY=... && python agente_manutencao.py`

12. Conclusões e Próximos Passos

12.1 Resultados Obtidos

A Sprint 2 entregou uma solução funcional de ponta a ponta, desde a análise exploratória até o agente conversacional operacional com diagnóstico em linguagem natural.

Entregável	Status	Resultado
------------	--------	-----------

Analise exploratoria com interpretacoes fisicas	Concluido	7 secoes, 7 figuras com texto analitico em markdown
Divisao temporal com justificativa	Concluido	Divisao cronologica por motor — sem data leakage
Random Forest com class_weight=balanced	Concluido	200 arvores, max_depth=20, 14 features
Comparacao com modelo linear (Reg. Logistica)	Concluido	RF supera LR em +14,7pp de F1-Macro
Curva ROC multiclasse	Concluido	AUC medio 0,983 — 4 classes one-vs-rest
Discussao critica de overfitting e metricas	Concluido	Gap 4,21pp; baseline trivial documentado; limitacoes dos dados sinteticos
Analise de erros por classe, motor e rampa	Concluido	59 erros detalhados; 87% concentrados em 5 motores
Agente com 3 cenarios e comunicacao de incerteza	Concluido	Funcional com tool_use Anthropic e fallback offline
Serializacao com metricas embutidas	Concluido	modelo_falhas.joblib inclui acuracia, F1-Macro e F1-Weighted
gerar_banco.py reproduzivel	Concluido	seed=42, funcoes separadas, saida de resumo automatica

12.2 Proximos Passos

- Testar LightGBM com SMOTE: objetivo principal e elevar o Recall do Desbalanceamento de 88% para acima de 92%.
- Aumentar a janela rolling de 5 para 10 a 15 leituras e adicionar uma feature de tendência linear (coeficiente angular da regressao sobre a janela).
- Implementar TimeSeriesSplit com 5 folds para uma estimativa mais robusta e honesta das métricas de generalização.
- Calibrar as probabilidades com CalibratedClassifierCV (regressão isotônica) para que os scores reflitam probabilidades reais.
- Analisar individualmente os 5 motores responsaveis por 87% dos erros para entender se sao outliers do dataset ou casos reais de dificuldade de generalização.
- Construir uma API REST com FastAPI para expor o modelo em produção e integra-la ao agente conversacional.

F1-Macro: 95,5% | Acurácia: 99,0% | AUC-ROC medio: 0,983

59 erros em 6.000 predições (0,98%) — concentrados no inicio da rampa de deterioração.

Principal ponto de atencao: Recall de 88% no Desbalanceamento.

Meta para a proxima etapa: superar 92% de Recall nessa classe.